

6. 使用高位作为标签可以提供足够的位数来唯一标识缓存行，可以支持更大的地址范围，而中间位作为标签则可能提供的位数较少，无法唯一标识缓存行，增加了冲突和缓存失效的风险。

7. ① 简化地址转换：位数相同则可以直接使用页偏移的位数，而无需进行额外的地址转换，提高了缓存系统的效率

② 硬件支持：可以更好地利用硬件支持，例如处理器可以直接使用虚拟地址的页偏移来缓存查找，而无需额外的逻辑操作

8. (1) $\bar{T} = 1 \cdot (1 - 3\%) + 110 \cdot 3\% = 4.27$ 周期

(2) $1GB \gg 64KB$ ，故每次访问都会导致缓存缺失， $\bar{T} = 110$ 周期

(3) (2) 中每次随机访问，导致无法利用局部性原理进行缓存命中，每次访问都会导致缓存缺失，导致访问延时较高

(4) 命中率 η : $1 \cdot \eta + 110(1 - \eta) \leq 105$
 $\therefore \eta \geq 4.59\%$ 即可

| 1. 编号 | 地址位数 (bit) | 缓存大小 (KB) | 块大小 (byte) | 相联度 | 组数量 | 组索引位数 | 标签位数 | 偏移位数 |
|-------|------------|-----------|------------|-----|-----|-------|------|------|
| 1 | 32 | 4 | 64 | 2 | 32 | 5 | 21 | 6 |
| 2 | 32 | 4 | 64 | 8 | 8 | 3 | 23 | 6 |
| 3 | 32 | 4 | 64 | 全相联 | 1 | 0 | 26 | 6 |
| 4 | 32 | 16 | 64 | 1 | 256 | 8 | 18 | 6 |
| 5 | 32 | 16 | 128 | 2 | 64 | 6 | 19 | 7 |
| 6 | 32 | 64 | 64 | 4 | 256 | 8 | 18 | 6 |
| 7 | 32 | 64 | 64 | 16 | 64 | 6 | 20 | 6 |
| 8 | 32 | 64 | 128 | 16 | 32 | 5 | 20 | 7 |

偏移位数 = $\log_2(\text{块大小})$

组数量 = 缓存大小 / 块大小 / 相联度

组索引位数 = $\log_2(\text{组数量})$

标签位数 = 地址位数 - 偏移位数 - 组索引位数

10. (1) $T_A = 0.22(1-P_1) + 100 \cdot P_1$, $T_B = 0.52(1-P_2) + 100 \cdot P_2$ A优于B 则 $T_A < T_B$

即 $99.78P_1 < 99.48P_2 + 0.30$

(2) $T_A = 0.22(1-P_1) + 0.22K P_1$, $T_B = 0.52(1-P_2) + 0.52K P_2$ $T_A < T_B$

即 $22(K-1)P_1 + 22 < 52(K-1)P_2 + 52$

$(K-1)(11P_1 - 20P_2) < 15$

11. 块地址即没有偏移量, 因为共有16个块, 故只需要最多4位索引, 即考察最后4位即可

0001 直接映射: 5次块替换

0101 2路组相联: 考虑后3位: 3次块替换

0101 4路组相联: 考虑后2位: 3次块替换

0101 8路组相联: 考虑后1位: 0次块替换

001 001
101 101

01 01 01 01

1 1 1 1 1 1 1

12. LRU: least-recently used 将最近最不常用的替换出去 32位: array[] 的地址
从 0, 4, 8, ..., 380
256/16 = 16 = 2^4 : 4位索引, 16个组
即 0000, 0100, ..., 10111100

~~j: 0 ~ 95 即 00000000 ~ 10111111~~

缓存B: 4位索引, tag: 0000 ~ 1011, 共计6种 tag, 每次改变 tag 就会发生1次 miss, tag 为 0 或 1
4位数据. 索引从 0000 ~ 1111

索引 1000 ~ 1111 的 tag 只有 0, 而索引 0000 ~ 0111 的 tag 为 0 和 1 交替

01000000 ~ 01111100 miss: 00000 0000, 0 0001 0000, ..., 00111 0000
128 ~ 252 10000 0000, 1 0001 0000, ..., 10111 0000

共计 miss $7 \times 2 = 14$ 个

10111100
index 偏移
缺失率为 $\frac{14}{96} \times 100\% = 14.6\%$

缓存A: 2路 3位索引, 2位 tag, 4位数据 索引: 000 ~ 111, tag: 00, 01, 10

考虑索引 000: ① 01_000 10_000 此时输入 00_000 miss 1次
同一个 i 下 按 LRU 替换

② 00_000 10_000 输入 01_000 miss 1次
③ 00_000 01_000 输入 10_000 miss 1次
④ 10_000 01_000

总计 miss $3 \times 8 = 24$ 次

缺失率 $\frac{24}{96} \times 100\% = 25\%$

13.

```
for (int j=0; j<128; ++j) {
    for (int i=0; i<64; ++i) {
        A[j][i] = A[j][i] + 1;
    }
}
```

 对应的 // 这样可以连续访问 $A[j][i]$ 和 $A[j][i+1]$ 这两个连续的地址

4. (1) 索引数 = $\frac{4KB}{32Byte} = 128$, 7位索引, 5位偏移

优化前: i : 64个地址连续 j : 128组不同的连续地址

而块大小只有32个字节, 说明同一个 j 中的索引会有差异, 即出现强制失效.

缺失次数: $128 \times \frac{64}{32} = 256$ 次

优化后: $128 \times \frac{64}{32} = 256$ 次

(2) FIFO: 先进先出 总计 1个组 128路 不需要索引

优化前: 恰 $j=128$ 对应 128路, $j=0$: 全 miss $j=1$ 全不 miss ... $j=32$: 全 miss ... $j=63$ 全不 miss

缺失次数: $128 \times 2 = 256$ 次

优化后: 仍是 256 次

(3) 8KB

15. 二维数组 行间地址不连续, 列间地址连续 数据: 4位, 索引: 1位

$input[0][0] \sim input[0][3]$ 地址: 0000 0000, 0000 0100, 0000 1000, 0000 1100.

索引

其它

故除了第一个 miss 都 hit

| | input 数组 | | | | output 数组 | | | |
|----|----------|-----|-----|-----|-----------|------|------|------|
| | 列0 | 列1 | 列2 | 列3 | 列0 | 列1 | 列2 | 列3 |
| 行0 | miss | hit | hit | hit | miss | miss | miss | miss |
| 行1 | miss | hit | hit | hit | miss | miss | miss | miss |
| 行2 | miss | hit | hit | hit | miss | miss | miss | miss |
| 行3 | miss | hit | hit | hit | miss | miss | miss | miss |

output 是固定列数, 改变行数

index

$output[0][0] \sim output[3][0]$: 地址: 0100 0000, 0101 0000, 0110 0000, 0111 0000

连续地址, 故全部 miss

1b. (1) 索引: $512 \div 2 \div 16 = 16 = 2^4$, 4位索引, 4位数据偏移. 两路组且用 LRU, 故分别存 $\text{input}[0][i]$ 和 $\text{input}[1][i]$
 $\text{input}[0][0] \sim \text{input}[0][15]$: 0000 0000 \sim 0111 1111

在索引达到 0000、0001、...、0111 时发生 miss, 共计 8 次

$$\therefore \text{命中率} = 1 - \frac{8}{128} = 93.75\%$$

(2) 不会, 因为不改变块大小的前提下增加总大小, 只会增加索引的位数,

索引仍会在 0000 \sim 0111 发生 miss, 故不改变命中率

(3) 可以, 因为增加块大小会将索引向左平移, 例如将块大小翻倍, 索引为 0000 \sim 0011

只会发生 4 次 miss, 提高了命中率.