

T6 ① 高位索引则相邻数据高位相同, 会产生缓存冲突。  
② 因为这种方法可以直接利用地址, 因为索引本身就是地址的中位, 比如: 若每个 Cache line 可存两个字节, 地址从 0 开始, 则若 Cache 有 4 个 line, 则内存 0110 的中位位 "11" 本身就代表了其映射到了第 3 个 line  
T7 这样的话, 可以直接用虚拟地址去 Cache 中访存, 能更高效地利用 Cache, 从而加快数据的读取、写速度

T8

- 1)  $\bar{T} = 110 \times 0.03 + 1 \times 0.97 = 4.27$
- 2) 缓存中有 64KB 的数据, 而总数据为 1GB  
访存是完全随机的, 则每次访存数据有  $\frac{64}{1048576}$   
 $= 0.06\%$  的概率在 cache 中, 因此  
 $\bar{T} = 0.06\% \times 1 + 99.94\% \times 110 = 110$
- 3) 局部性原理指的是 CPU 访存时, 都趋于访问聚集在一个较小的连续区域内的数据。  
若局部性原理成立, 则将访问的数据附近的一些数据也放入缓存中, 则后面访存时大概率会访到缓存中的数据, 例如 1) 中 97% 的命中率, 则访存周期会大大减少, 而若没有局部性原理, 则如 2), 缓存的利用率会大大降低, 从而访存周期大大增加

$$4) \bar{p} + (1-\bar{p}) \cdot 110 < 105$$

32

T9

编号1:	32组	5 Bit	21 Bit	6 Bit
编号2:	8组	3 Bit	23 Bit	6 Bit
编号3:	1组	0 Bit	26 Bit	6 Bit
编号4:	256组	8 Bit	18 Bit	6 Bit
编号5:	64组	6 Bit	19 Bit	7 Bit
编号6:	256组	8 Bit	18 Bit	6 Bit
编号7:	64组	6 Bit	20 Bit	6 Bit
编号8:	32组	5 Bit	20 Bit	7 Bit

T10

$$1) 0.22(1-p_1) + 100 \cdot p_1 < 0.52(1-p_2) + 100 \cdot p_2$$

$$2) 0.22(1-p_1) + k \cdot 0.22 \cdot p_1 < 0.52(1-p_2) + k \cdot 0.52 \cdot p_2$$

T11

0001	0000	0000	0001	块内偏移为 $\log_2(64) = 6 \text{ Bit}$ 直接映射: 4 Bit: 替换 3 次 2 路: 3 Bit: 替换 1 次 4 路: 2 Bit: 替换 1 次 8 路: 1 Bit: 替换 0 次
0001	0000	0000	0101	
0001	0000	0000	0001	
0001	0000	0100	0101	
0001	0000	0100	0101	
0001	0000	0100	0101	
0010	1110	1110	0101	
1111	1111	0000	0101	

T12

只计算稳态:

直接映射: 一路, 16组, 一组=一块, 每块中16字节, 4个字节, 4个数组元素, 且稳态时, 数组的32~63个元素一直在8~16组中, 因此这些元素不会miss, 而剩余的, 都是4个里面miss一个, 命中3个

$$\therefore \text{miss\_rate} = \frac{2}{3} \cdot \frac{1}{4} = \frac{1}{6}$$


2路并联: LRU, 则每4个miss 1个命中3个, 所以

$$\text{miss\_rate} = \frac{1}{4}$$

T13 for (int j=0; j<1024; ++j) {

for (int i=0; i<64; ++i)

A[j][i] += i; }



T14

16 ~ 15

A[j][i]

1) 4KB, 块大小为32B, 则8个word, 能存放8个数组元素, 且共有  $(4 \times 1024) / 32 = 128$  个块, 且 A[j][i] 与 A[j+1][i] 之间相差 64, 即8个块

① 未优化之前: 每次缺失时存入的8个数据, 除了立刻会使用的那个, 剩下的7个, 在被利用之前就被冲刷掉了. 因此缺失次数是  $128 \times 64 = 8192$  次

② 优化后: 每次miss后读入的剩下7个数据会立刻被利用,  $\therefore \text{miss\_rate} = \frac{1}{8} \therefore \text{miss} = 1024$  次

2) ①未优化前: 128个块,  $j$  有128行, 正好每过一个  $j$  的循环数组的每行读取8个数据进去, 则后7个数据在下一次  $j$  循环会利用, 所以  $\text{miss\_rate} = \frac{1}{8}$ ,  $\therefore \text{miss} = 1024$

②: 优化后: 仍是  $\frac{1}{8}$   $\text{miss\_rate}$ ,  $\therefore \text{miss} = 1024$

3) ①优化前: 最好是读入块的8个元素, 除了强制缺失的一个, 其余都能被 hit 到, 则对于优化前代码这等于要求, 每次遍历一次  $j$ , 都不会有缓存冲突, 而又因为是直接映射, 这等于要求缓存能放下整个数组, 即:  $64 \times 128 \times 4 = 32\text{KB}$

②优化后: 反正每次读入之后, 强制缺失之外的7个会马上 hit, 所以一个块就行. 32B 就行。

T15

output	0	1	2	3	input	0	1	2	3
0	miss	miss	miss	miss	0	miss	miss	hit	miss
1	miss	miss	miss	miss	1	hit	miss	miss	hit
2	miss	miss	miss	miss	2	miss	miss	hit	miss
3	miss	miss	miss	miss	3	hit	miss	miss	hit

T16

- 1) 每次更新缓存时, 将  $\text{input}[0][\text{init}]$  读入第一路的某一组, 再将  $\text{input}[1][\text{init}]$  读入第二路的某一组, 这样之后的  $\text{init}$  数据会命中, 因此命中率为  $\frac{3}{4}$
- 2) 不会, 因为每个数据只会用一次, 而块大小不变, 因而都是  $\text{input}[i][i] \mid i=0, 3, 7, \dots$  的会 miss, 而其余的会命中, 因此命中率总是  $\frac{3}{4}$
- 3) 会, 若将块大小更新至大于 4 个字, 例如 8 个字, 则就会成为每 8 个数组元素中 miss 一个, 则命中率会变为  $\frac{7}{8}$

