

YOLO 卷积函数的 SMART 仿真

一、实验目的

通过将 YOLO 源码的卷积函数放在 SMART 上进行仿真和性能监测，进一步介绍嵌入式 C 裸机程序在 C910 上的开发过程和仿真原理。通过观测分支预测开关对程序性能的影响，理解分支预测在现代处理器中的重要性。通过指令分布统计，了解内存墙的概念，并进一步理解缓存在现代处理器中的重要性。

二、实验步骤（包括实验结果，数据记录、截图等）

1. 文件核对和执行仿真

1) 进入 smart9_release 工作目录，输入以下命令完成文件替换

```
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release>[57]cp -rf /home/ECDesign/ECDesign_share/lab9/ ~
cp: overwrite '/home/ECDesign/ecd09/lab9/Makefile'? y
cp: overwrite '/home/ECDesign/ecd09/lab9/conv_test/data_in'? y
cp: overwrite '/home/ECDesign/ecd09/lab9/conv_test/conv_test.c'? y
cp: overwrite '/home/ECDesign/ecd09/lab9/conv_test/conv_test.h'? y
cp: overwrite '/home/ECDesign/ecd09/lab9/conv_test/work.h'? y
cp: overwrite '/home/ECDesign/ecd09/lab9/conv_test/inst_proc'? y
cp: overwrite '/home/ECDesign/ecd09/lab9/crt0.s'? y
cp: overwrite '/home/ECDesign/ecd09/lab9/soc.v'? y
cp: overwrite '/home/ECDesign/ecd09/lab9/tb.v'? y
cp: overwrite '/home/ECDesign/ecd09/lab9/conv_test.h'? y
cp: overwrite '/home/ECDesign/ecd09/lab9/axi_slave128_copy.v'? y
cp: overwrite '/home/ECDesign/ecd09/lab9/pmu.h'? y
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release>[58]y
y: Command not found.
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release>[59]cp -f ~/lab9/axi_slave128_copy.v ./rtl/platform/amba/axi/
cp: cannot stat '/home/ECDesign/ecd09/lab9/axi': No such file or directory
cp: cannot stat 'slave128': No such file or directory
cp: cannot stat 'copy.v': No such file or directory
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release>[60]cp -f ~/lab9/axi_slave128_copy.v ./rtl/platform/amba/axi/
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release>[61]ls
./ case/ lib/ readme run_smart* setup.csh tmp/ workdir/
../ debug_test/ mem_intf/ rtl/ script/ tb/ tools/
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release>[62]cp -f ~/lab9/soc.v ./rtl/platform/common/
cp: overwrite './rtl/platform/common/soc.v'? y
```

```
cp: overwrite './rtl/platform/common/soc.v'? y
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release>[63]cp -f ~/lab9/Makefile ./lib/
cp: overwrite './lib/Makefile'? y
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release>[64]cp -f ~/lab9/tb.v tb/
cp: overwrite 'tb/tb.v'? y
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release>[65]cp -f ~/lab9/pmu.h ./lib/clib/
cp: overwrite './lib/clib/pmu.h'? y
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release>[66]cp -rf ~/lab9/conv_test.h conv_test/
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release>[66]cp -rf ~/lab9/conv_test/ case/
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release>[67]
```

2) 在 workdir 目录下输入以下命令进行仿真

```
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release>[67]cd workdir/
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/smart9_release/workdir>[68]../tools/run_case ../case/conv_test/conv_test.c
```

（这是第一次仿真失败的截图，之后为了节省时间，创建了 lab9_hdw 文件夹，将 smart9

文件夹分别复制到 1, 2, 3 目录进行仿真)

提交仿真后在目录 case/conv_test/ 下对生成的二进制文件执行 `../../tools/toolchain/RV64GC/bin/riscv64-unknown-elf-objdump -S conv_test.elf > conv_test.s` 可以进行反汇编

gvim 查看 conv_test.s, 找到其中的 guard_start 和 guard_end 的重定向入口分别为 1b50 和 1c10

```
void guard_start()
{
    1b50:      1141
    1b52:      e406
}

void guard_end()
{
    1c10:      1141
    1c12:      e406
}
```

核对 tb/tb.v 中开头部分的定义:

```
`define GUARD_START_PC      40'h1850
`define GUARD_END_PC        40'h1910
```

发现两者并不相符, 应当将 tb.v 中的宏定义进行修改, 使之相匹配

```
`define GUARD_START_PC      40'h1b50
`define GUARD_END_PC        40'h1c10
```

终止之前的仿真任务, `bkill -r [任务号]` 删除 conv_test.s 并重新提交任务

之后再次查看 conv_test.s 和 tb.v 中的宏定义, 确认两者一致后即可等待结果。

2) 打开 lib 目录下的 crt0.s

```
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/lab9_hdw/3/smart9_release/workdir
>[133]
```

可看到刚才是对 all prediction on 的情况进行仿真, 接下来分别取消对应的注释, 分别对三种情况进行仿真。

```
li x3, 0x10f7      #all prediction on
#li x3, 0x00b7      #BTB, L0BTB off
#li x3, 0x0007      #all prediction off
```

仿真结束后打开 run.log 对仿真结果进行查看, 并填入下表

Simulation 1 (all prediction on)	Simulation 2 (BTB, L0BTB off)
num_cycle is 5202663	num_cycle is 5131578
num_instret is 9449136	num_instret is 9449136
CPI is 0.550597	CPI is 0.543074
num_conditional_branch_mis is 4439	num_conditional_branch_mis is 5006
num_L1_Dcache_read_access is 3780647	num_L1_Dcache_read_access is 3795212
num_L1_Dcache_read_miss is 14250	num_L1_Dcache_read_miss is 14227
num_L1_Dcache_write_access is 1897811	num_L1_Dcache_write_access is 1898553
num_L1_Dcache_write_miss is 1858	num_L1_Dcache_write_miss is 1827
num_L2_Dcache_read_access is 469435	num_L2_Dcache_read_access is 470737
num_L2_Dcache_read_miss is 4164	num_L2_Dcache_read_miss is 4164
num_L2_Dcache_write_access is 121027	num_L2_Dcache_write_access is 121008
num_L2_Dcache_write_miss is 399	num_L2_Dcache_write_miss is 399
guard_cycle_count is 5203315	guard_cycle_count is 5132230
guard_inst_count is 8681109	guard_inst_count is 8724951
***** * simulation finished successfully *	***** * simulation finished successfully *

```

num_cycle is 8936645
num_instret is 9449136
CPI is 0.945763
num_conditional_branch_mis is 253598
num_L1_Dcache_read_access is 4579889
num_L1_Dcache_read_miss is 12291
num_L1_Dcache_write_access is 1920568
num_L1_Dcache_write_miss is 1805
num_L2_Dcache_read_access is 481926
num_L2_Dcache_read_miss is 4183
num_L2_Dcache_write_access is 122750
num_L2_Dcache_write_miss is 400
guard_cycle_count is      8937286
guard_inst_count is      8718437
*****
* simulation finished successfully *
*****

```

2. CPI、Cache 缺失率和分支预测统计

configure	all prediction off	BPE on, BTB off	all prediction on
cycle	8936645	5202663	5131578
insts	9449136	9449136	9449136
CPI	0.945763	0.550597	0.543074
conditional branch miss	253598	4439	5006
L1_Dread access	4579889	3780647	3795212
L1_Dread miss	12291	14250	14227
L1_Dread miss_rate	0.002683689	0.003769196	0.003748671
L1_Dwrite access	1920568	1897811	1898553
L1_Dwrite miss	1805	1858	1827
L1_Dwrite miss_rate	0.000939826	0.000979023	0.000962312
L2_Dread access	481926	469435	470737
L2_Dread miss	4183	4164	4164
L2_Dread miss_rate	0.008679756	0.008870238	0.008845704
L2_Dwrite access	122758	121027	121008
L2_Dwrite miss	400	400	399
L2_Dwrite miss_rate	0.003258443	0.003305048	0.003297303

3. 指令分布统计绘图

将 inst_proc 复制到 workdir 目录下执行，并对各类型数据进行统计得到下图

```

admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/lab9_hdw/1/smart9_release/workdir
>[183]cp -f ../case/conv_test/inst_proc ./
cp: overwrite './inst_proc'? y
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/lab9_hdw/1/smart9_release/workdir
>[184]chmod +x inst_proc
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/lab9_hdw/1/smart9_release/workdir
>[185]./inst_proc
inst_class created.
admin:/home/ECDesign/ecd09/huangdaiwei_21307140008/lab9_hdw/1/smart9_release/workdir
>[186]gvim inst_class

```

```

memory access instructions:
  memory load:    3711234
  memory store:   1879215


arithmetic instructions:
  integer operation:    464726
  floating point operation: 1653916

branch instructions:
  conditional branch:    504007
  unconditional branch: 57642

atomic instructions:    0
cache manipulation instructions (C910 customized extension): 71981
other instructions:    183617

total: 8526338

```



4. Optional
inst_count 截图

op[1:0]=11:		op[1:0]=00:	
00:	1	0:	0
01:	3711233	1:	0
02:	71981	2:	0
03:	0	3:	0
04:	317720	4:	0
05:	0	5:	0
06:	18347	6:	0
07:	0	7:	0
08:	15		
09:	1879200	op[1:0]=01:	
0a:	0	0:	103486
0b:	0	1:	3554
0c:	25348	2:	80099
0d:	17	3:	6
0e:	99751	4:	0
0f:	0	5:	0
10:	1622932	6:	2882
11:	0	7:	0
12:	0		
13:	0	op[1:0]=10:	
14:	30984	0:	0
15:	0	1:	0
16:	0	2:	0
17:	0	3:	0
18:	501125	4:	0
19:	0	5:	0
1a:	0	6:	0
1b:	57642	7:	0
1c:	15		
1d:	0		
1e:	0		
1f:	0		

insec_record 截图

retire0:000000b72	retire0:000000b5a
retire1:000000b76	retire0:000000b62
retire0:000000b7a	retire1:000000b66
retire1:000000b7e	retire0:000000b6a
retire0:000000b84	retire1:000000b6e
retire0:000000b46	retire0:000000b72
retire0:000000b4a	retire1:000000b76
retire0:000000b4e	retire0:000000b7a
retire1:000000b52	retire1:000000b7e
retire0:000000b56	retire2:000000b84
retire1:000000b5a	retire0:000000b46
retire0:000000b62	retire0:000000b4a
retire1:000000b66	retire0:000000b4e
retire0:000000b6a	retire1:000000b52
retire1:000000b6e	retire0:000000b56
retire0:000000b72	retire1:000000b5a
retire1:000000b76	retire0:000000b62
retire0:000000b7a	retire1:000000b66
retire1:000000b7e	retire0:000000b6a
	retire1:000000b6e
	retire0:000000b72
	retire1:000000b76
	retire0:000000b7a
	retire1:000000b7e
	retire2:000000b84

三、实验分析和总结

(一)实验分析

1. 对 Cache 缺失率的统计

- (1) 条件分支语句的缺失数量，当 BPE 打开而 BTB 关闭的时候缺失数量最少，而在所有预测关闭的时候缺失数量最大；
- (2) L1 L2 的读缺失，当 BPE 打开而 BTB 关闭的时候缺失率最高，当分支预测全部关闭时缺失率最低；
- (3) L1 L2 的写缺失，当 BPE 打开而 BTB 关闭的时候缺失率最高，当分支预测全部关闭时缺失率最低；

分析：

由于本实验中的读写缺失率都非常低且相差很小，所以其实分支预测和 cache 关系并不明显；

在其他分支预测器都开启的情况下，打开 BTB 反而会提升缺失率：分支预测导致进入了某些本来不会执行的控制流，虽然最后会被取消，但仍然会造成额外的 cache 访问；

- Cache 大小对实验结果影响不大的原因是：由 inst_record 可以看出，该函数循环重复多次。由 cache 的工作原理可知，它会将程序高频的代码和数据存放在其中，便于寻找。而循环的重复率很高，其他非循环内部的指令与数据相对较少，因此能够非常轻易的将所需要的绝大部分数据与指令存放在 cache 中，且所占存储并不会非常高，故 miss rate 很低且随着 cache 大小变化不大。

```
retire0:000000b72
retire1:000000b76
retire0:000000b7a
retire1:000000b7e
retire0:000000b84
retire0:000000b46
retire0:000000b4a
retire0:000000b4e
retire1:000000b52
retire0:000000b56
retire1:000000b5a
retire0:000000b62
retire1:000000b66
retire0:000000b6a
retire1:000000b6e
retire0:000000b72
retire1:000000b76
retire0:000000b7a
retire1:000000b7e
retire2:000000b84
```

2. 对 CPI 统计

随着分支预测开关的逐步打开，CPI 递减，CPU 性能递增；

正如实验 8 中分析过的，分支预测可以预先知晓需要跳转的目标地址，使得程序进行到分支语句时所需要的周期数更少，从而使得 CPI 更低，CPI 的下降也意味着 CPU 性能的提升。

3. C 程序在 smart 的仿真流程

要将 C 程序放入 smart 平台进行仿真，主要要经过三个前期准备阶段，分别是：源码编译和链接、生成便于 RTL 仿真模型加载的文件以及加载指令和数据到仿真模型。

- (1) 源码编译和链接：smart 平台使用哈佛架构，将数据和指令分离，分别存放在 MEM1 和 MEM2 中。在程序开始仿真时，CPU 从起始地址 (0x0) 开始读取，即从 crt0.o 开始读取。在对各种寄存器、栈指针等初始化后，跳转到用户提交的 C 程序主函数入口开始执行，并生成完全链接的二进制文件 (.elf)。
- (2) 生成便于 RTL 仿真模型加载的文件：文件每行小端存放 4 组 4 个字节的数据，便于 testbench 读入；
- (3) 加载指令和数据到仿真模型：模型每次传出 16 字节的数据，而 pc 使用其最低 4 位对模块内的数据进行寻址，从而确定具体对应的字节。接着 tb.v 将数据读入中间数组，并使用 initial 过程对内存模型初始化。其中链接脚本 linker.lcf 所划分的 MEM1、MEM2 和栈空间，其地址全部落在 SRAM_START 和 SRAM_END 之间，因此总是操作 x_axi_slave128 这一模块内的内存模型。

4. 内存墙与指令统计

- (1) 定义：内存墙指内存性能严重限制 CPU 性能发挥的现象。在过去的二十多年中，处理器的发展速度与内存的发展速度严重失衡。处理器以每年 55% 左右的速度进行发展，而内存发展速度仅为 10% 左右。所以如今，DRAM 传输速度不断增加，但访问延迟较大的问题始终无法解决。

DRAM 延迟使得 CPU 需要花时间等待内存访问完成，带来限制 CPU 性能、增加 CPU 发热量等问题。因此，科学家将这种现象称为内存墙。

- (2) 解决方法：内存的主要衡量标准是带宽和等待时间。因此要提高内存的能力，就需要从这两个方面入手。

🔧 提高内存带宽：内存带宽=（传输倍率×总线位宽×工作频率）÷8，因此，可以通过提高总线位宽、提高工作频率和提高内存传输倍率（如将 DDR 内存改为 DDR2 或 DDR3）

🔧 降低等待时间：运用 cache，根据时间区域性原理，将处理器可能访问的数据和代码预先存储到高速缓存中，使得程序对于高频数据的访问时间大大缩小，从而降低等待时间。

(3) 在本次试验中，可以看出在指令统计中加载与存储（访存类指令）总共占了指令总数的 66%，远高于算术运算指令的 24%与分支指令的 7%。因此可以看出，在现代处理器中，由于内存墙的存在，访存类指令占据了 CPU 性能的绝大部分，对 CPU 的性能造成了极大的限制。也进一步说明了缓存的重要性。

4. Optional

🔧 insc_count 解析

通过实验指导文档可知，在 risc-V 指令集中可通过判断最低的两位来判断指令属于 32 位 (G, 2'b11) 或 16 位 (C, 2'b00、2'b01、2'b10)，同时结合高三位编码来判断具体指令类型

查阅 risc-V 可知部分指令对应的编码如下，由于篇幅过长，只截取部分

31	27	26	25	24	20	19	15	14	12	11	7	6	0	
funct7				rs2		rs1		funct3		rd		opcode		R-type
imm[11:0]						rs1		funct3		rd		opcode		I-type
imm[11:5]				rs2		rs1		funct3		imm[4:0]		opcode		S-type
imm[12:10:5]						rs1		funct3		imm[4:1:11]		opcode		B-type
				imm[20:11:19:12]						rd		opcode		U-type
				imm[20:10:11:19:12]						rd		opcode		J-type


RV32I Base Instruction Set														
imm[31:12]						rd		0110111		LUI				
imm[31:12]						rd		0010111		AUIPC				
imm[20:10:11:19:12]						rd		1101111		JAL				
imm[11:0]				rs1		000		rd		1100111		JALR		
imm[12:10:5]				rs2		rs1		000		imm[4:1:11]		BEQ		
imm[12:10:5]				rs2		rs1		001		imm[4:1:11]		BNE		
imm[12:10:5]				rs2		rs1		100		imm[4:1:11]		BLT		
imm[12:10:5]				rs2		rs1		101		imm[4:1:11]		BGE		
imm[12:10:5]				rs2		rs1		110		imm[4:1:11]		BLTU		
imm[12:10:5]				rs2		rs1		111		imm[4:1:11]		BGEU		
imm[11:0]						rs1		000		rd		LB		
imm[11:0]						rs1		001		rd		LH		
imm[11:0]						rs1		010		rd		LW		
imm[11:0]						rs1		100		rd		LBU		
imm[11:0]						rs1		101		rd		LHU		
imm[11:5]				rs2		rs1		000		imm[4:0]		SB		
imm[11:5]				rs2		rs1		001		imm[4:0]		SH		
imm[11:5]				rs2		rs1		010		imm[4:0]		SW		
imm[11:0]				rs1		000		rd		010011		ADDI		
imm[11:0]						rs1		010		rd		SLTI		
imm[11:0]						rs1		011		rd		SLTIU		
imm[11:0]						rs1		100		rd		XORI		
imm[11:0]						rs1		110		rd		ORI		
imm[11:0]						rs1		111		rd		ANDI		
0000000				shamt		rs1		001		rd		SLI		
0000000				shamt		rs1		101		rd		SRLI		
0100000				shamt		rs1		101		rd		SRAI		
0000000				rs2		rs1		000		rd		ADD		
0100000				rs2		rs1		000		rd		SUB		
0000000				rs2		rs1		001		rd		SLL		
0000000				rs2		rs1		010		rd		SLT		
0000000				rs2		rs1		011		rd		SLTU		
0000000				rs2		rs1		100		rd		XOR		
0100000				rs2		rs1		101		rd		SRL		
0000000				rs2		rs1		110		rd		SRA		
0000000				rs2		rs1		111		rd		OR		
fm				pred		succ		rs1		000		rd		AND
0000000000000						00000		000		00000		1110011		FENCE
0000000000001						00000		000		00000		1110011		EBREAK

funct7	rs2	rs1	funct3	rd	opcode	R-type
imm[11:0]			rs1		rd	LD
imm[11:5]			rs1	funct3	rd	I-type
imm[11:5]	rs2	rs1	funct3	imm[4:0]	opcode	S-type

RV64I Base Instruction Set (in addition to RV32I)														
imm[11:0]						rs1		110		rd		LWU		
imm[11:0]						rs1		011		rd		LD		
imm[11:5]				rs2		rs1		011		imm[4:0]		SD		
0000000				shamt		rs1		001		rd		SLLI		
0000000				shamt		rs1		101		rd		SRLI		
0100000				shamt		rs1		101		rd		SRAI		
imm[11:0]						rs1		000		rd		ADDIW		
0000000				shamt		rs1		001		rd		SLLIW		
0000000				shamt		rs1		101		rd		SRLIW		
0100000				shamt		rs1		101		rd		SRAIW		
0000000				rs2		rs1		000		rd		ADDW		
0100000				rs2		rs1		000		rd		SUBW		
0000000				rs2		rs1		001		rd		SLW		
0000000				rs2		rs1		101		rd		SRLW		
0100000				rs2		rs1		101		rd		SRAW		

RV32/RV64 Zifencei Standard Extension					
imm[11:0]	rs1	001	rd	0001111	FENCE.

以上某一分类的总和基本上与 `insc_count` 中的结果一致

 `insc_record` 解析

图片和分析见上

四、实验收获、存在问题、改进措施或建议等

通过本次实验，具体操作了将 YOLO 源码放到 smart 平台上进行仿真的过程，了解了 C 语言在 smart 平台上仿真的步骤与原理，理解了内存墙的概念，并且进一步深入了解了分支预测与 cache 在现代处理器中的重要性。